

# 卒業研究報告書

---

題 目

遺伝的アルゴリズムによる機械学習における  
疑似ラベル生成手法の提案

---

研究グループ 知能情報第1グループ

指導教員 森 直樹 教授

平成 32 年 ( 2020 年 ) 度 卒 業

(No. ) 細川 岳大

---

大阪府立大学工学部知能情報工学科

## 目次

1	はじめに	1
2	要素技術	2
2.1	半教師あり学習	2
2.2	疑似ラベル	2
2.3	FixMatch	2
2.3.1	RandAugment	2
2.3.2	Consistency Regularization	3
2.3.3	更新	3
2.4	SimCLR	4
2.4.1	Cotrastive Learning	4
2.5	ResNet	5
2.6	Genetic Algorithm	5
2.6.1	選択	6
2.6.2	交叉	6
2.6.3	突然変異	7
3	提案手法	8
4	数値実験	9
5	結論	10
	謝辞	11
	参考文献	12

## 図 目 次

2.1	FixMatch の概略図 . . . . .	3
2.2	SimCLR の概略図 . . . . .	4
2.3	Residual Block の構造 . . . . .	6

## 表 目 次

## 1 はじめに

近年、機械学習の発展に伴い、様々な分野への応用がされており様々な新規データセットにおいて目覚ましい結果が報告されている。また新規データセットを生成する際、分類問題では各データにふさわしいラベル付けをする必要があり、ラベル付けには人の手が必要でありコストがかかる問題がある。そこで半教師あり学習 (Semi-Supervised Learning: SSL)<sup>[1]</sup> と呼ばれる学習データ全体のうち一部にのみラベルが付与された状態で学習を行う手法が提案されており、盛んに研究されており、全データにラベルが付与されている教師あり学習にも劣らない成果の報告<sup>[2]</sup>もある。しかし、当然のことながら各ラベルに対するデータ数が少ないほど精度が安定しなくなるという報告もされている。

一方、ラベルなしデータへのラベル付けタスクは一種の組合せ最適化問題と考えることができる。

本研究では、組合せ最適化遺伝的アルゴリズムを用いてデータにラベルを付与することでラベル付きデータが少ない場合における半教師あり学習の頑健性を高める手法を提案する。

以下に本欄分の構成を示す。まず、2章では本研究で用いる要素技術について概説する。続いて3章で実験手法の提案をし、4章において実験結果と考察を示す。5章で本研究の成果をまとめたうえで、今後の課題について述べる。

## 2 要素技術

本章では，実験に関連する要素技術について説明する．

### 2.1 半教師あり学習

半教師あり学習 (Semi Supervised Learning: SSL)<sup>[1]</sup> は大量のラベルなしデータと少量のラベル付きデータを用いて学習を行う手法である．

### 2.2 疑似ラベル

疑似ラベル (Pseudo Label)<sup>[3]</sup> はあるモデルによって予測されるラベルなしデータに対する暫定的なラベルである．SSL では疑似ラベルを付与したデータをラベル付きデータに混ぜて学習することで各ラベル同士に対する確率分布を粗密なものにする作用があり，正則化の役割をする．データ数を  $N$ ，あるモデルによる予測確率を  $q_b$ ，予測確率  $p, q$  に対する Cross Entropy Loss を  $H(p, q)$ ，閾値を  $\tau$  とするとき，(2.2) 式で与えられる．

$$\hat{q}_b = \operatorname{argmax}(q_b) \quad (2.1)$$

$$\frac{1}{N} \sum_{b=1}^N \mathbb{1}(\max(q_b) \geq \tau) H(\hat{q}_b, q_b) \quad (2.2)$$

### 2.3 FixMatch

FixMatch<sup>[2]</sup> は SSL の一つである．図 2.1 に FixMatch の概略図を示す．疑似ラベルと Consistency Regularization の二つの正則化手法を統合させた手法であり，FixMatch の強変換として使用される．

#### 2.3.1 RandAugment

RandAugment<sup>[4]</sup> とは，データ拡張手法の一つであり，チューニングするパラメータは  $N$  と  $M$  の二種類で，複数あるデータ変換操作のうちランダムに  $N$  個選択し変換強度  $M$  で順に適用する手法である．

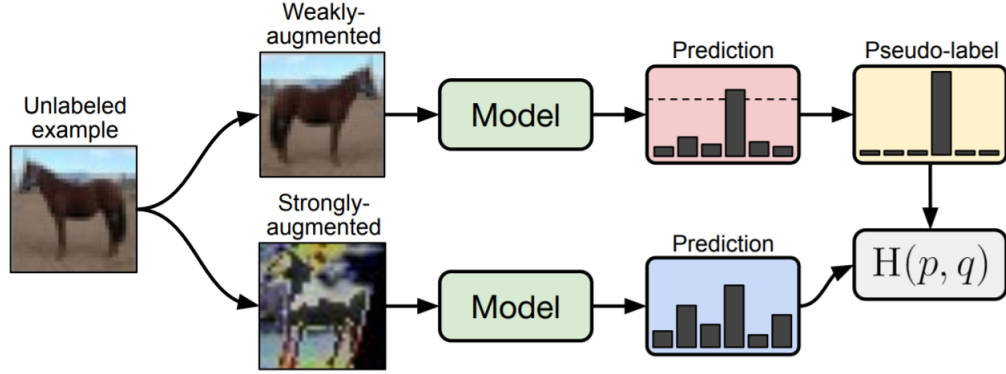


図 2.1: FixMatch の概略図：文献<sup>[2]</sup>の Figure 1 を参照

### 2.3.2 Consistency Regularization

Consistency Regularization<sup>[5]</sup> は正則化手法の一つであり，画像による変換の前後で予測値が変わらないようなロスを与える．ラベルなしデータを  $u_b$ ， $\alpha(\cdot)$  を画像変換， $p_m(y|x)$  を入力  $x$  に対するモデルの出力とすると，(2.3) 式で与えられる．

$$\sum_{b=1}^N ||p_m(y|\alpha_1(u_b)) - p_m(y|\alpha_2(u_b))||_2^2 \quad (2.3)$$

### 2.3.3 更新

まず，バッチサイズを  $B$  としラベル付きデータを  $\mathcal{X} = (x_b, p_b) : b \in (1, \dots, B)$  としたとき，ラベル付きデータに対するロス  $\ell_s$  とすると，(2.4) 式で与えられる．

$$\ell_s = \frac{1}{B} \sum_{b=1}^B H(p_b, p_m(y|\alpha(x_b))) \quad (2.4)$$

また，ラベルなしデータに対するロス  $\ell_u$  は，(2.2)，(2.3) 式より，

$$\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbb{1}(\max(q_b) \geq \tau) H(\hat{q}_b, p_m(y|\mathcal{A}(u_b))) \quad (2.5)$$

となる．このとき， $\mu$  はバッチ内のラベル付きデータに対するラベルなしデータの比率， $\mathcal{A}(\cdot)$  を強変換である．

従って、ラベルなしデータの重みを  $\lambda$  として、バッチ全体のロス  $\ell_s + \lambda \ell_u$  となる。

## 2.4 SimCLR

Simple framework for Contrastive Learning of visual Representation(SimCLR)<sup>[6]</sup> は SSL の一つである。図 2.2 に概略図を示す。モデルの構造は Encoder, Projection Head, Classifier から構成されており、Encoder と Projection Head に対して、全データを用いて Contrastive Learning によって学習する。次に学習済みの Encoder と Classifier に対して、ラベル付きデータを用いて Classifier の学習を行う。最後にモデルの蒸留を行うことで最終的なモデルを得る。

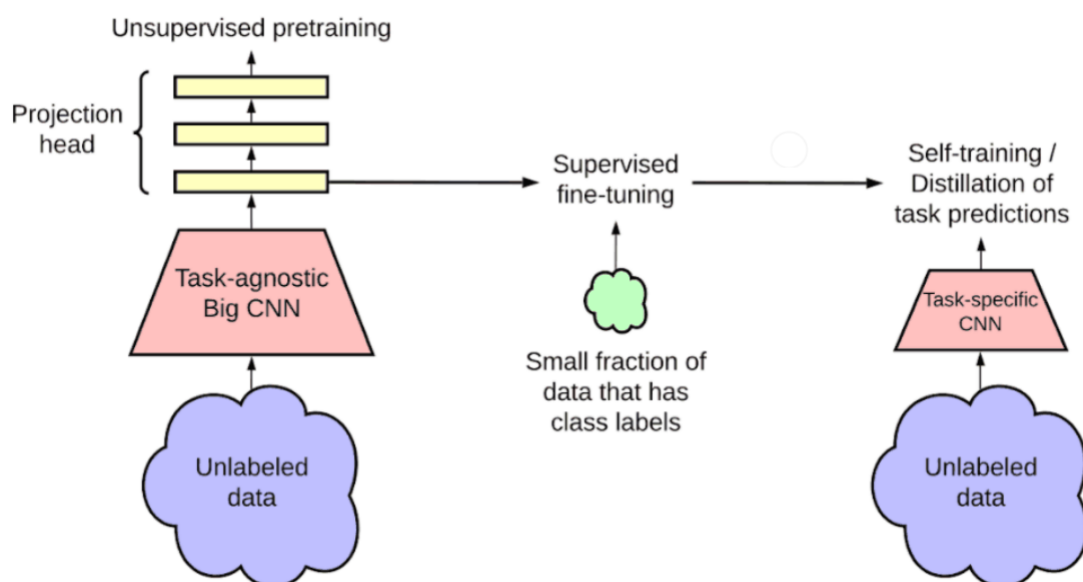


図 2.2: SimCLR の概略図：文献<sup>[7]</sup>の Figure 3 を参照

### 2.4.1 Contrastive Learning

Contrastive Learning (CL)<sup>[8]</sup> とは特徴表現を獲得するための自己教師あり学習のひとつである。ある画像変換をした画像のペアについて元画像が一致するか否かを識別するタスクであり、一つの画像から得られる特徴表現が画像



変換によって画像の持つ意味が大きく変化させない変形を獲得することができる．具体的な方法について，バッチ内の画像枚数を  $N$  枚とすると，Data Augmentation によって2倍に増やしたとき，各画像に対して正例は1枚，負例は  $2(N-1)$  枚となる．このとき特徴ベクトル間の距離として  $\cos$  類似度を用い，(2.6) 式となる．また，正例との距離を小さくかつ，負例との距離を大きくするために正例のペア  $(z_i, z_j)$  に対するロス  $\ell(i, j)$  は (2.7) 式で表され，バッチ全体のロス  $\mathcal{L}$  は (2.8) 式で表される．

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T \mathbf{v} / \|\mathbf{u}\| \|\mathbf{v}\| \quad (2.6)$$

$$\ell(i, j) = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)} \quad (2.7)$$

$$\mathcal{L} = \frac{1}{2N} \sum_{k=1}^N [\ell(2k-1, 2k) + \ell(2k, 2k-1)] \quad (2.8)$$

## 2.5 ResNet

Residual Network (: ResNet)<sup>[9]</sup> は Deep Neural Network (: DNN) のモデルの一つであり，DNNにおいて層を深くすることで発生する劣化問題及び勾配消失問題を解消するために残差についての学習を行うことを目的としている．図 2.3 に ResNet の構成要素である Residual Block の構造を示す．2層の畳み込み層とショートカットの足し合わせた構造となっている．

## 2.6 Genetic Algorithm

遺伝的アルゴリズム (Genetic Algorithm: GA)<sup>[11]</sup> とは，生物の進化を模倣した組合せ最適化問題のアルゴリズムである．解の要素の最小単位を遺伝子，遺伝子の集まりである解を個体として表現する．また個体の集合を世代とし，各個体の計算された適応度をもとに選択，交叉，突然変異の3つの操作によって新たな個体群を生成し，次世代の個体集合とする．繰り返し世代を重ねることで最適解を探索する．個体の基本的なエンコーディング方法として，バイナ




図 2.3: Residual Block の構造：文献<sup>[10]</sup>の Figure 2.(a) を参照

り型，順列型，実数型，整数型がある．本研究では整数型について扱うため，以下整数型を前提とした説明をする．

### 2.6.1 選択

選択は自然淘汰をもとにした操作であり，個体の適応度にもとづき次世代に残される個体を選ぶものである．以下のものがあげられる．

- エリート選択<sup>[12]</sup>：世代における適応度の最も高い個体を他の操作を行わず次世代に残す手法である．
- トーナメント選択：個体群からランダムに決められた数（：トーナメントサイズ）取り出し，その中で適応度の最も高い個体を選択する手法である．

### 2.6.2 交叉

交叉は生物の交配をもとにした操作であり，二つの個体から新たな2つの個体を生成するものである．以下のものがあげられる．

- エリート選択<sup>[12]</sup>：世代における適応度の最も高い個体を他の操作を行わず次世代に残す手法である．

- トーナメント選択：個体群からランダムに決められた数（: トーナメントサイズ）取り出し，その中で適応度の最も高い個体を選択する手法である。

### 2.6.3 突然変異

個体の遺伝子を変化させる操作で，局所探索になることを防ぐ．乱数によって他の取りうる値に変化させる．また，突然変異率を上げすぎるとランダム探索となり，収束しなくなるため，高くても数%に設定されることが多い．

### 3 提案手法

本研究では，ラベルなしデータに対する疑似ラベルを遺伝的アルゴリズムを用いて探索する手法を提案する．

## 4 数值実験

## 5 結論

## 謝辞

## 参考文献

- [1] Xiaojin Jerry Zhu. Semi-supervised learning literature survey. 2005.
- [2] Kihyuk Sohn, David Berthelot, Chun-Liang Li, Zizhao Zhang, Nicholas Carlini, Ekin D Cubuk, Alex Kurakin, Han Zhang, and Colin Raffel. Fix-match: Simplifying semi-supervised learning with consistency and confidence. *arXiv preprint arXiv:2001.07685*, 2020.
- [3] Dong-Hyun Lee et al. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on challenges in representation learning, ICML*, volume 3, 2013.
- [4] Ekin D Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V Le. Randaugment: Practical automated data augmentation with a reduced search space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 702–703, 2020.
- [5] Han Zhang, Zizhao Zhang, Augustus Odena, and Honglak Lee. Consistency regularization for generative adversarial networks. *arXiv preprint arXiv:1910.12027*, 2019.
- [6] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pages 1597–1607. PMLR, 2020.
- [7] Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi, and Geoffrey Hinton. Big self-supervised models are strong semi-supervised learners. *arXiv preprint arXiv:2006.10029*, 2020.
- [8] Yonglong Tian, Chen Sun, Ben Poole, Dilip Krishnan, Cordelia Schmid, and Phillip Isola. What makes for good views for contrastive learning. *arXiv preprint arXiv:2005.10243*, 2020.



- [9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Identity mappings in deep residual networks. In *European conference on computer vision*, pages 630–645. Springer, 2016.
- [11] Darrell Whitley. A genetic algorithm tutorial. *Statistics and computing*, 4(2):65–85, 1994.
- [12] Tadahiko Murata, Hisao Ishibuchi, and Hideo Tanaka. Multi-objective genetic algorithm and its applications to flowshop scheduling. *Computers & industrial engineering*, 30(4):957–968, 1996.
- [13] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009.
- [14] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning. *arXiv preprint arXiv:2004.11362*, 2020.